Conceptos Básicos de Inteligencia Artificial y Aprendizaje Automático para la Investigación

Clase 1: Introducción, Análisis y Visualización de datos con Python

Dr. Juan Claudio Toledo Roy
Instituto de Ciencias Nucleares UNAM

¿Qué veremos en esta clase?

- Python como lenguaje de análisis y visualización de datos
- Librerías principales de Python para análisis de datos
- Análisis exploratorio de datos (EDA)
- Lectura y limpieza de datos
- Visualización de datos

Datos y ejemplos: https://github.com/meithan/Curso_IA_Investigacion

Generalidades de Python

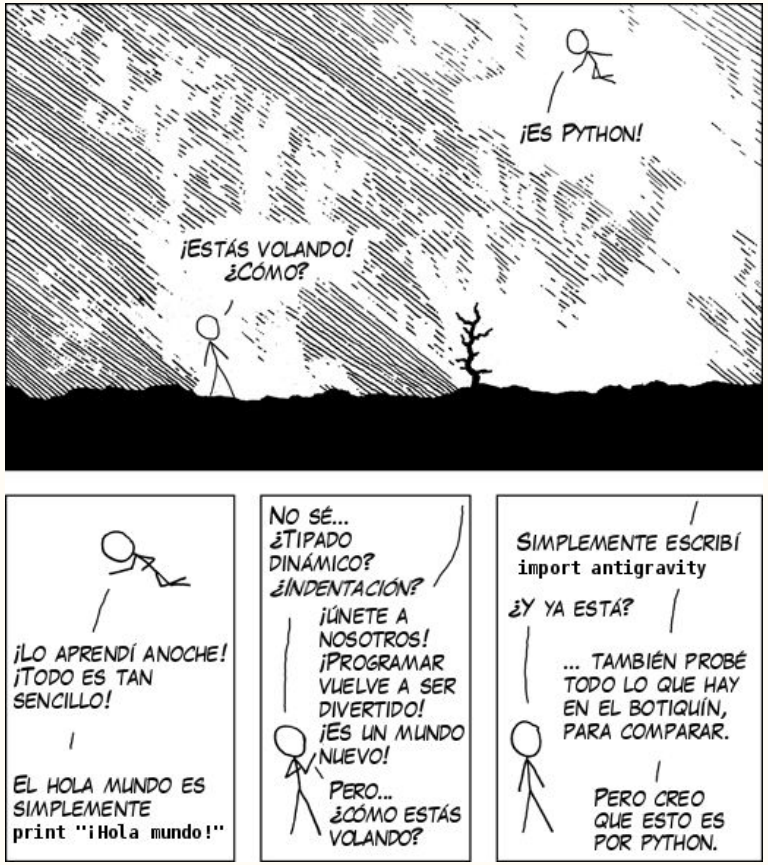

https://xkcd.com/353/

Generalidades de Python

- Creado por Guido van Rossum en 1991 (¡anterior a Java!)
- Versión 2.0 en 2000, versión 3.0 en 2008; última: 3.13 (2024)
- Versión 3 no compatible hacia atrás; ¡no usar Python 2!
- Nombre inspirado en el grupo de comediantes británicos Monty Python

Generalidades de Python

Python es el lenguaje más usado actualmente.

Jan 2026	Jan 2025	Change	Programming Language	Ratings	Change
1	1		Python	22.61%	-0.68%
2	4	↑	C	10.99%	+2.13%
3	3		Java	8.71%	-1.44%
4	2	↓	C++	8.67%	-1.62%
5	5		C#	7.39%	+2.94%
6	6		JavaScript	3.03%	-1.17%
7	9	↑	Visual Basic	2.41%	+0.04%
8	8		SQL	2.27%	-0.14%
9	11	↑	Delphi/Object Pascal	1.98%	+0.19%
10	18	⇈	R	1.82%	+0.81%

https://www.tiobe.com/tiobe-index/

Generalidades de Python

Características principales:

- Lenguaje de (muy) **alto nivel**
- **Dinámicamente tipado**, **bytecode interpretado**
- Sintaxis **ligera, intuitiva** y **poderosa**
- **Multi-paradigma**: procedural, orientado a objetos, funcional, etc.
- **Extensa librería estándar** (estructuras de datos, matemáticas, tipos de datos, etc)
- **Multi-plataforma** y tremendamente ubicuo
- **Ecosistema** de terceros **muy amplio**

Generalidades de Python

Pero ...

- **Lento** en comparación de otros lenguajes, sobre todo compilados
  - Compilado a bytecode (aunque Java también y es bastante más rapido)
  - Tipado dinámico y “duck typing”
  - Todo es un objeto

- Está diseñado para ser **sintáticamente poderoso** y **ligero**, no para ser rápido

- Hay formas de acelerarlo, sobre todo vía librerías como **Numpy**

- Existen algunos **compiladores** avanzados (PyPy, Numba)

Generalidades de Python

Python nativo
¡Ouch!

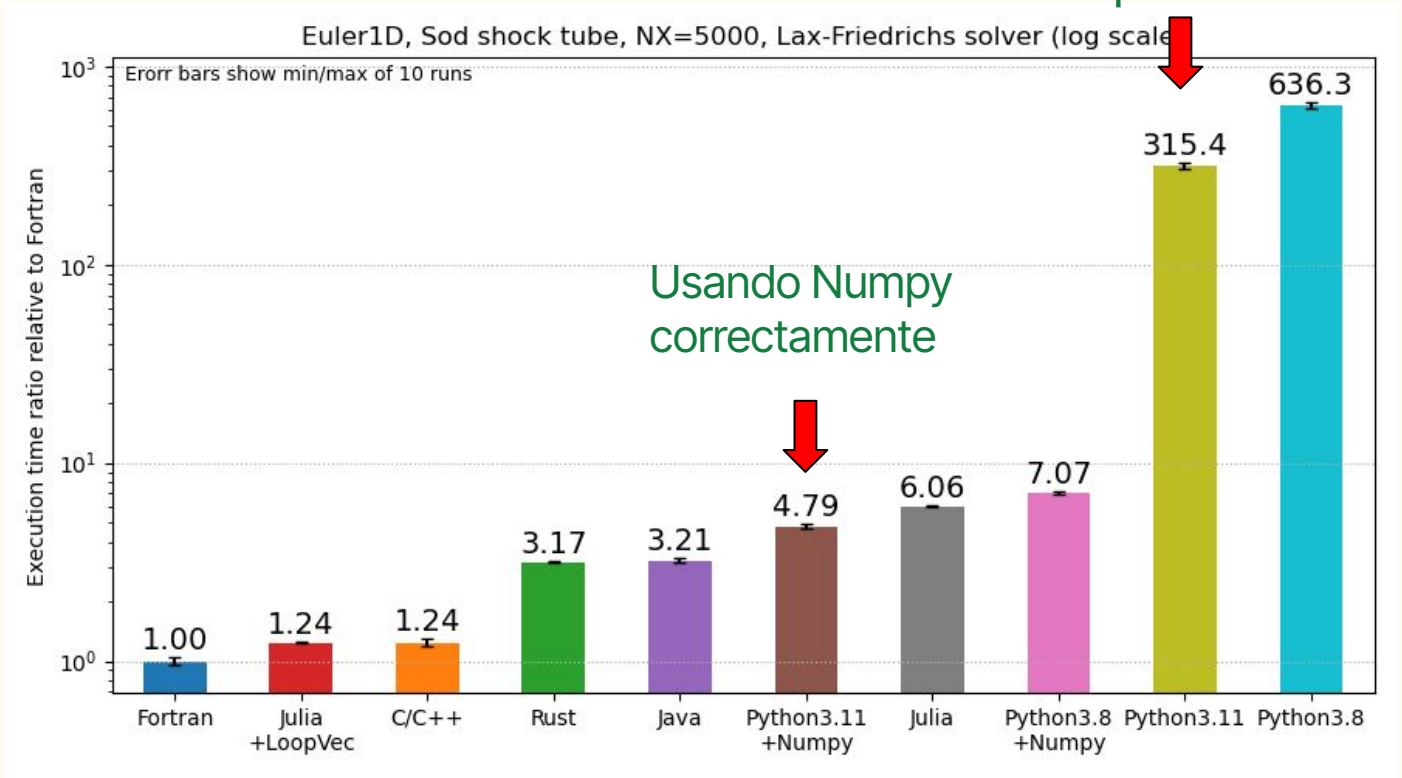

Generalidades de Python

The Zen of Python

El estilo “Pythónico” de programación.

- Ejecutar `import this`

```
Bello es mejor que feo.
Explícito es mejor que implícito.
Simple es mejor que complejo.
Complejo es mejor que complicado.
Plano es mejor que anidado.
Espaciado es mejor que denso.
La legibilidad es importante.
...
```

```
for i in range(len(array)):
    print(array[i])
```

```
for item in array:
    print(item)
```

Instalación y uso de Python

Instalación

- Directamente desde la página oficial: https://www.python.org/downloads/
- Vía una distribución como Anaconda: https://www.anaconda.com/download

Uso

- Editor de código (Notepad++, Atom, VS Code) + terminal
- IDE, por ejemplo PyCharm
- IDE en web: Jupyter Notebook, Google Colab

Python como lenguaje de análisis de datos

Capacidades para análisis y visualización de datos

- Python en sí tiene **pocas** herramientas de análisis/visualización de datos

- Pero amplio y muy activo ecosistema de **librerías de terceros**:

    - **NumPy**: cómputo numérico y herramientas matemáticas
    - **SciPy**: cómputo científico y herramientas avanzadas
    - **Matplotlib**: graficación y visualización de datos
    - **Seaborn**, **plotly**: graficación interactiva
    - **pandas**: especializada en análisis de datos
    - **scikit-learn**: machine learning
    - **NetworkX**: análisis de redes
    - **PyTorch**, **TensorFlow**: deep learning

Python como lenguaje de análisis de datos

- La gran mayoría de estas librerías de terceros están en **PyPI** (Python Package Index) y se pueden instalar muy fácilmente usando **`pip`**

Python como lenguaje de análisis de datos

- Hoy en día, lo recomendado oficialmente es usar **virtual environments** (**venvs**)

  - Ambiente aislado (independiente del sistema) con paquetes específicos
  - Control fino de versión de paquetes
  - Entorno reproducible (se puede copiar el venv)
  - No requiere privilegios elevados (administrador)

1. Crear venv nuevo (en cualquier carpeta del usuario)

```
❯ python -m venv test
```

2. Activar el venv en la sesión actual (en terminal)

```
❯ source test/bin/activate
```

La terminal usualmente indicará el venv activo:

```
test❯
```

3. Instalar paquetes con pip

```
test❯ pip install matplotlib
```

4. Se puede desactivar el venv:

```
test❯ deactivate
```

Python como lenguaje de análisis de datos

- Alternativamente, se pueden usar entornos de Python en web como **Google Colab** y **JupyterLab** (pero dependen de un servicio ofrecido por terceros)

- Para las demostraciones del curso, usaremos **MACTI**, una plataforma en línea para enseñanza en cómputo del ICN que incluye JupyterLab

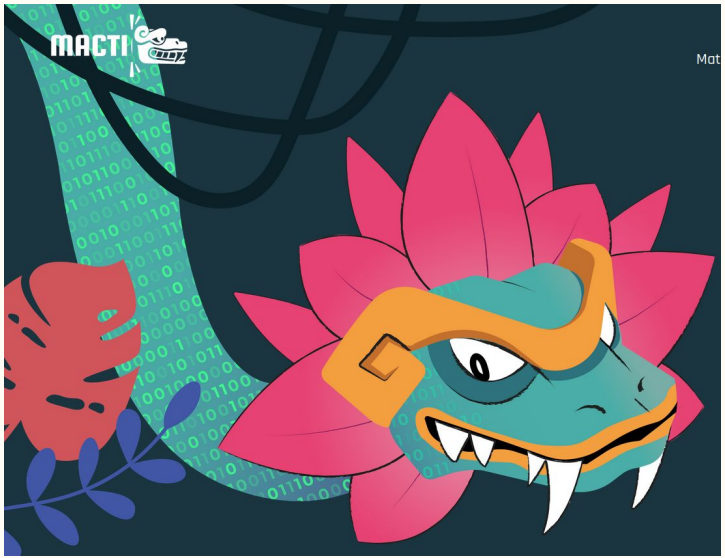

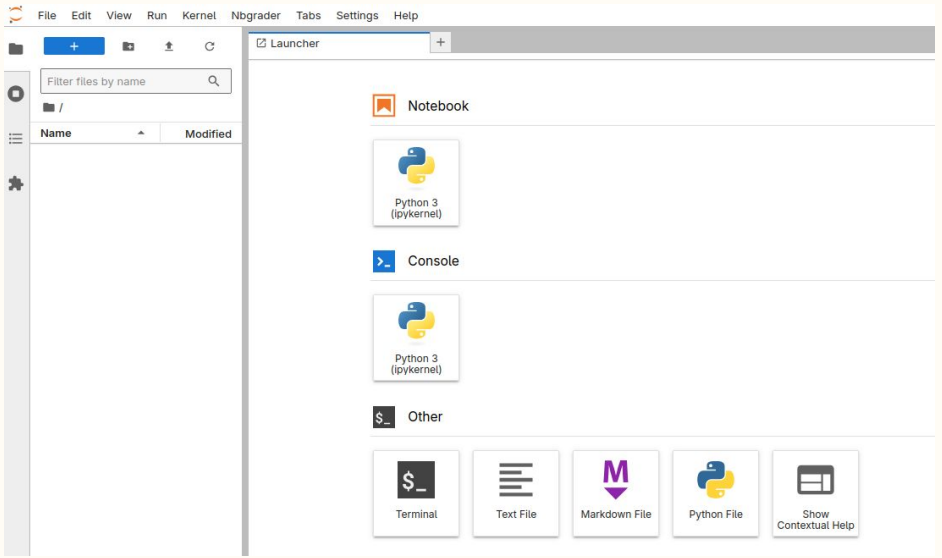

Análisis Exploratorio de Datos (EDA)

- **Explorar** un conjunto de **datos** para entender su **estructura**, **características** y potenciales **problemas** antes de aplicar métodos de análisis más formales

1. **Aprender la estructura de los datos**
    - ¿Qué variables están presentes?
    - ¿De qué tipo son (numéricas, categóricas, temporales)?
    - ¿Cuántos datos (observaciones) hay?

2. **Valorar la calidad de los datos**
    - Valores faltantes
    - Valores duplicados
    - Valores inconsistentes o imposibles
    - Valores atípicos (outliers)

(continúa)

Análisis Exploratorio de Datos (EDA)

3. **Visualizar características principales**
   - Tendencia central (media, mediana, etc)
   - Variabilidad (desviación estándar, IQR, etc)
   - Distribución (sesgos, centralidad, etc)

4. **Identificar (visualmente) patrones y relaciones**
   - Correlaciones entre variables
   - Diferencias entre grupos
   - Tendencias y periodicidades temporales

5. **Guía para análisis subsecuente**
   - ¿Qué herramientas de análisis se pueden usar?
   - ¿Cuáles modelos o pruebas se pueden aplicar?

Regla de oro: antes de aplicar cualquier análisis
¡VISUALIZAR LOS DATOS!

Tipos de archivos de datos

- **Texto plano**:
  - Legible por humanos
  - Simple, transparente, portable
  - Poco eficiente (espacio)
  - Necesario saber cómo interpretarlo
  - Formatos comunes: txt, csv, tsv
  - También formatos de texto estructurado: JSON, XML, etc.

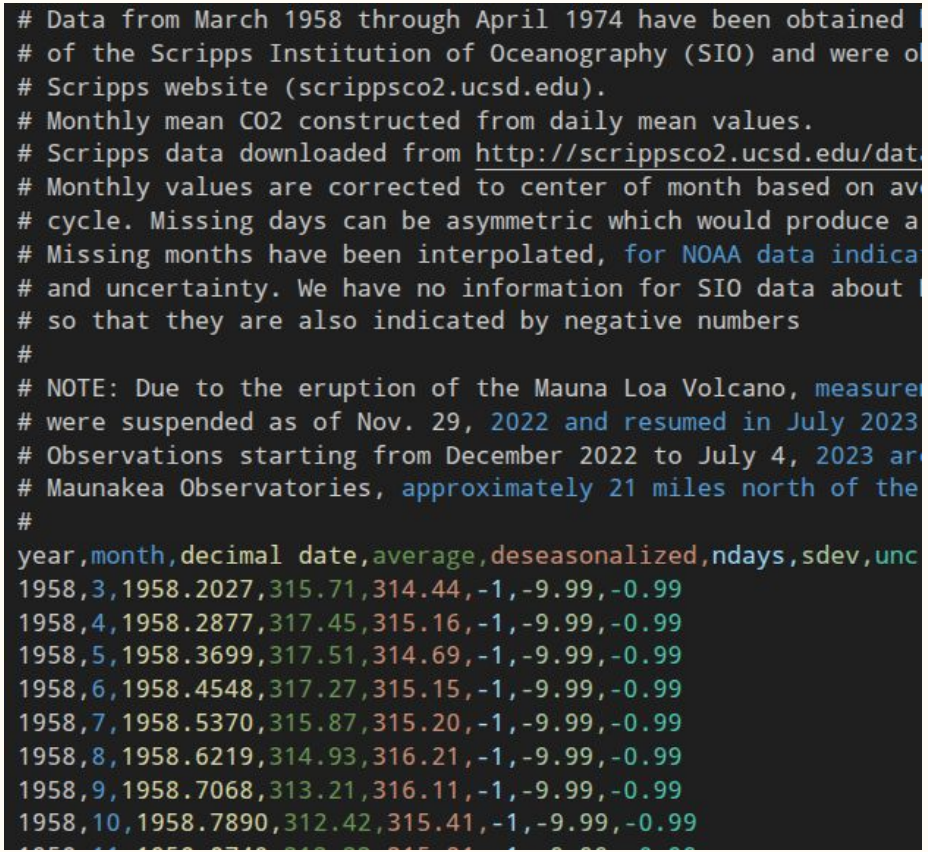

```
# Data from March 1958 through April 1974 have been obtained
# of the Scripps Institution of Oceanography (SIO) and were o
# Scripps website (scrippsco2.ucsd.edu).
# Monthly mean CO2 constructed from daily mean values.
# Scripps data downloaded from http://scrippsco2.ucsd.edu/dat
# Monthly values are corrected to center of month based on av
# cycle. Missing days can be asymmetric which would produce a
# Missing months have been interpolated, for NOAA data indica
# and uncertainty. We have no information for SIO data about
# so that they are also indicated by negative numbers
#
# NOTE: Due to the eruption of the Mauna Loa Volcano, measure
# were suspended as of Nov. 29, 2022 and resumed in July 2023
# Observations starting from December 2022 to July 4, 2023 ar
# Maunakea Observatories, approximately 21 miles north of the
#
year,month,decimal date,average,deseasonalized,ndays,sdev,unc
1958,3,1958.2027,315.71,314.44,-1,-9.99,-0.99
1958,4,1958.2877,317.45,315.16,-1,-9.99,-0.99
1958,5,1958.3699,317.51,314.69,-1,-9.99,-0.99
1958,6,1958.4548,317.27,315.15,-1,-9.99,-0.99
1958,7,1958.5370,315.87,315.20,-1,-9.99,-0.99
1958,8,1958.6219,314.93,316.21,-1,-9.99,-0.99
1958,9,1958.7068,313.21,316.11,-1,-9.99,-0.99
1958,10,1958.7890,312.42,315.41,-1,-9.99,-0.99
```

Tipos de archivos de datos

- Formatos **binarios**:
  - No legible por humanos, sí por máquinas
  - Compacto (espacio), rápido de leer en la computadora
  - Necesario saber cómo interpretarlo, pero suelen contener metadata
  - Usualmente hay librerías para leerlos
  - Ejemplos: formatos estándar científicos (HDF5, NetCDF, FITS, MAT), formatos binarios ad hoc
- Otros:
  - Hojas de cálculo (Excel)
  - Bases de datos (MySQL, SQLite)

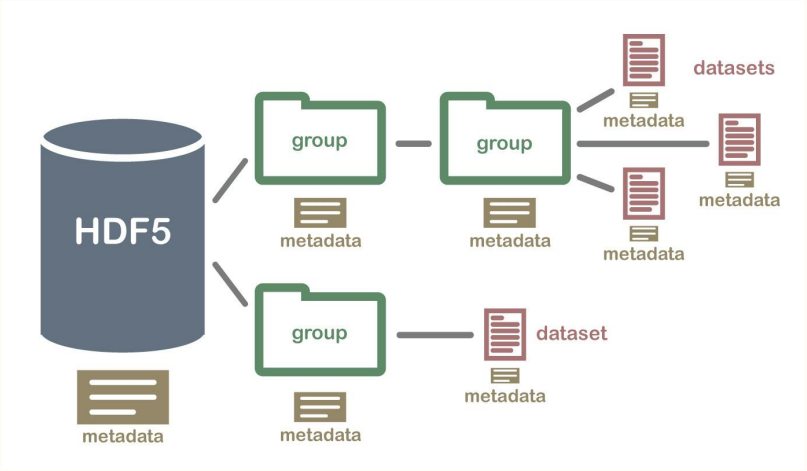

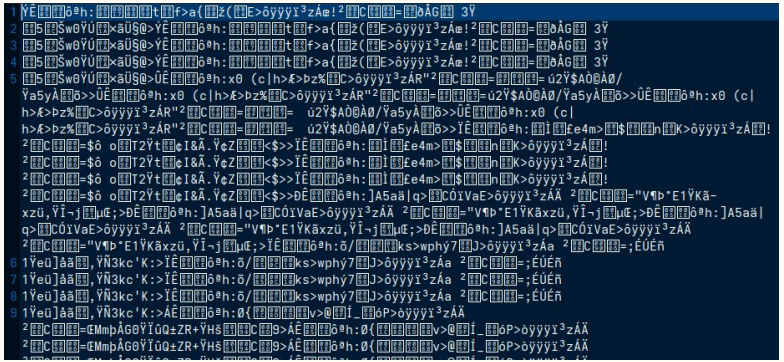

Lectura de datos en Python

- Usando funciones básicas de Python (archivos de texto, CSVs, etc)

```
datos = []
with open(“sunspots.dat”) as f:
  line = f.readline()
  for line in f:
    x, y = [float(d) for d in line.split()]
    datos.append((x, y))
```

Sin argumentos, `split()` separa un string usando *whitespace* (espacios, tabulaciones, saltos de línea), uno o más.

También se le puede pasar un string como separador, por ejemplo `split(“, “)`

sunspots.dat

```
1850.001 100
1850.004 133
1850.007 85
1850.010 114
1850.012 52
1850.015 57
1850.018 107
1850.021 75
1850.023 40
1850.026 50
1850.029 65
1850.031 85
1850.034 99
1850.037 77
1850.040 73
1850.042 34
1850.045 74
```

Lectura de datos en Python

- Usando la librería nativa **`csv`** de Python (CSVs, TSVs)

```
import csv
datos = []
with open("CO2.csv") as f:
  reader = csv.reader(f)
  for row in reader:
    mes = float(row[0])
    CO2 = float(row[1])
    datos.append((mes, CO2))
```

¿En qué difiere de leerlo "a mano"?

Que `csv.reader` va a parsear correctamente texto que contiene comas (si es un CSV correcto)

CO2.csv

```
Year,CO2 (ppm)
1958.208,  315.71
1958.292,  317.45
1958.375,  317.50
1958.458,  317.10
1958.542,  315.86
1958.625,  314.93
1958.708,  313.20
1958.792,  312.66
1958.875,  313.33
1958.958,  314.67
1959.042,  315.62
1959.125,  316.38
1959.208,  316.71
1959.292,  317.72
1959.375,  318.29
1959.458,  318.15
```

Lectura de datos en Python

- Usando **Numpy** (datos en ASCII o binario, CSVs, etc)

```
import numpy as np
datos = np.loadtxt(“CO2.csv”, skiprows=1, delimiter=”,”)
print(datos)
print(datos.shape)
type(datos)
```

  - Devuelve un array de Numpy (más poderosos y eficientes que las listas de Python)
  - Convierte en automático a números (floats o ints)
  - El archivo debe contener sólo números, y mismo número de valores por fila
  - Se pueden brincar líneas de encabezado y comentarios
  - Se puede cambiar el `delimiter` de las columnas (default es espacio)

Lectura de datos en Python

- Usando **pandas** (múltiples formatos)

```
import pandas as pd
df = pd.read_csv(“CO2.csv”)
print(df)
print(type(df))
print(df.columns)
print(df["CO2 (ppm)"])
```

  - Reconoce automáticamente encabezados, se brinca comentarios, etc.
  - Devuelve un DataFrame de pandas (objeto de datos sofisticado)
  - Columnas pueden ser de tipos de datos mixtos (p.ej. fechas formateadas)
  - Un poco más opaco, hay que aprender a usarlo
  - Un poco más pesado y lento

Lectura de datos en Python

- Formatos especializados/propietarios: usualmente hay librerías de terceros en Python

Ejemplo: formato **EDF** (series de tiempo médicas), **`PyEDFlib`**

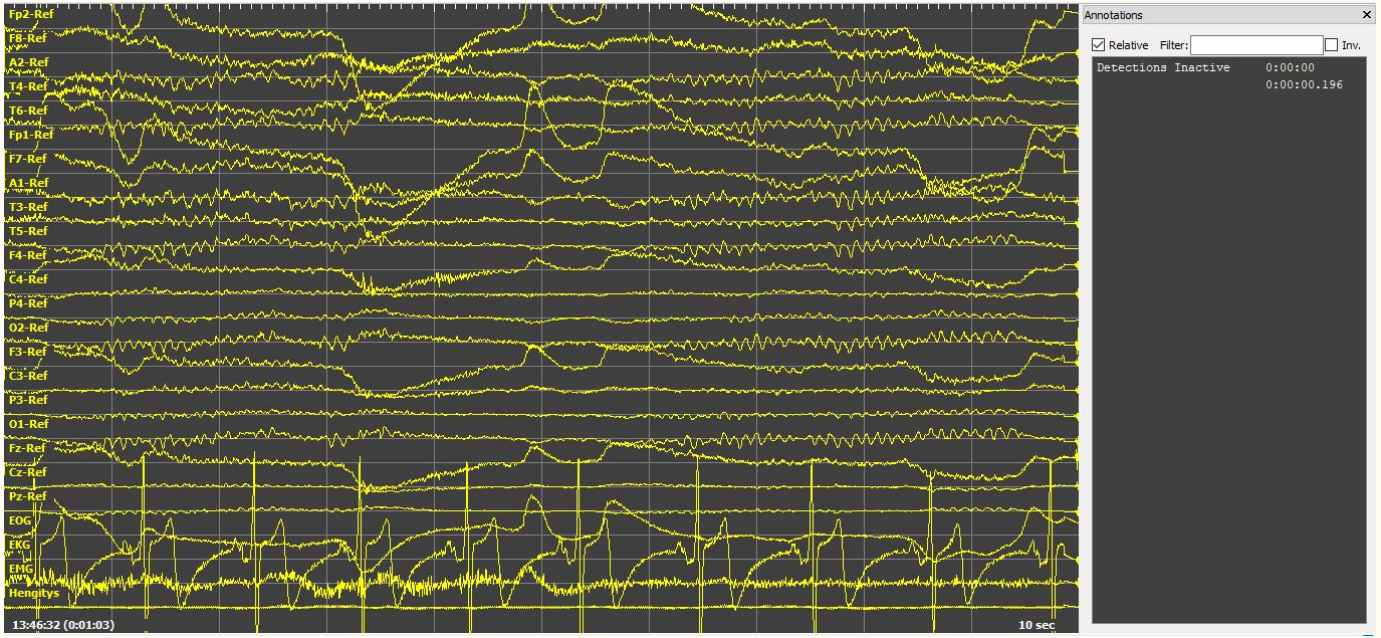

Lectura de datos en Python

- Formatos especializados: usualmente hay librerías de terceros en Python

  Ejemplo: formato **NetCDF** (series de tiempo y datos geoespaciales), **`netCDF4`**

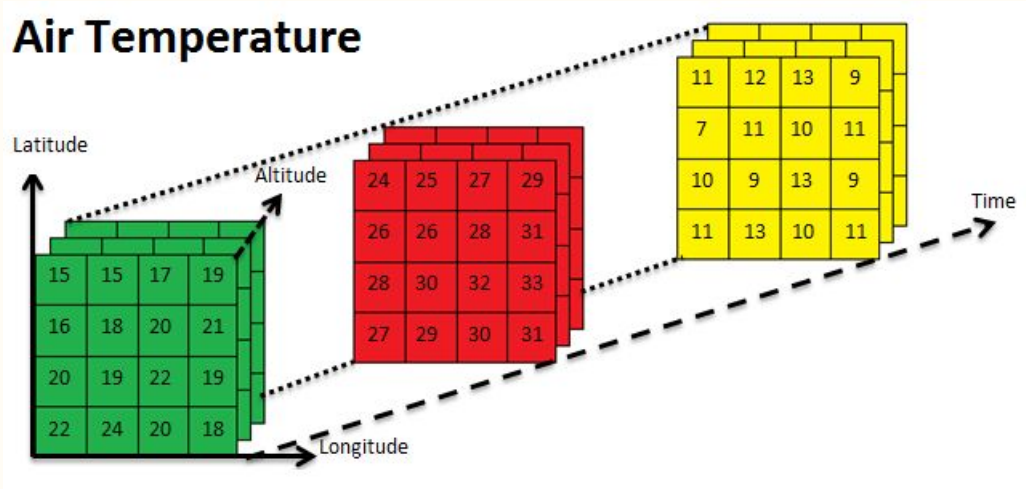

Visualización en Python con matplotlib

- **matplotlib** es una poderosa librería de graficación y visualización
- Muchos tipos de gráficos: líneas, scatters, barras, heatmaps, vectores, 3D, etc.
- Se usa mucho en conjunto con Numpy (de hecho, es una dependencia)

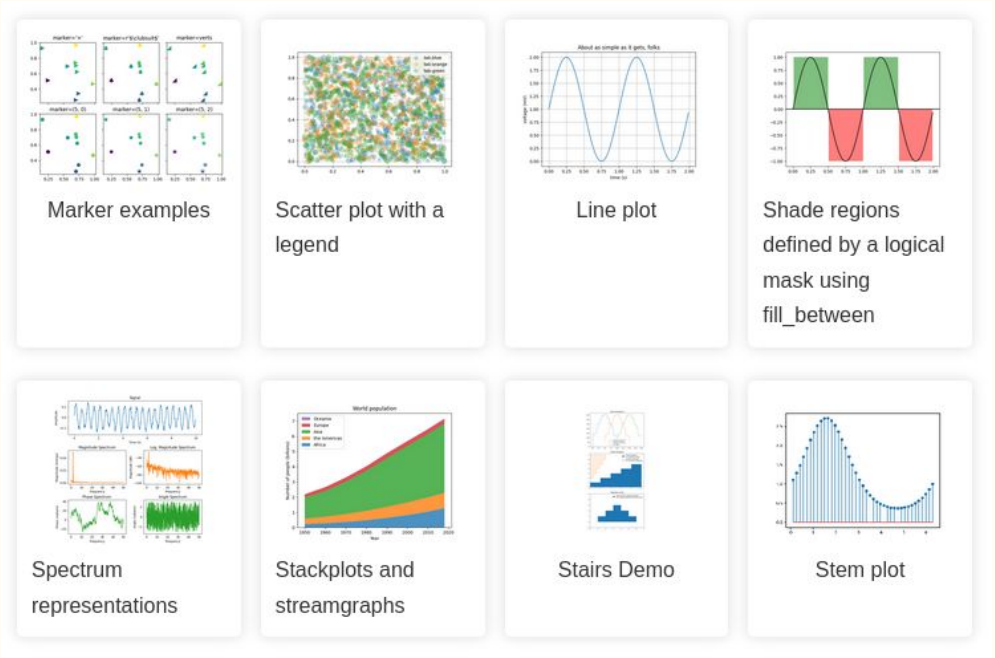

https://matplotlib.org

Visualización en Python con matplotlib

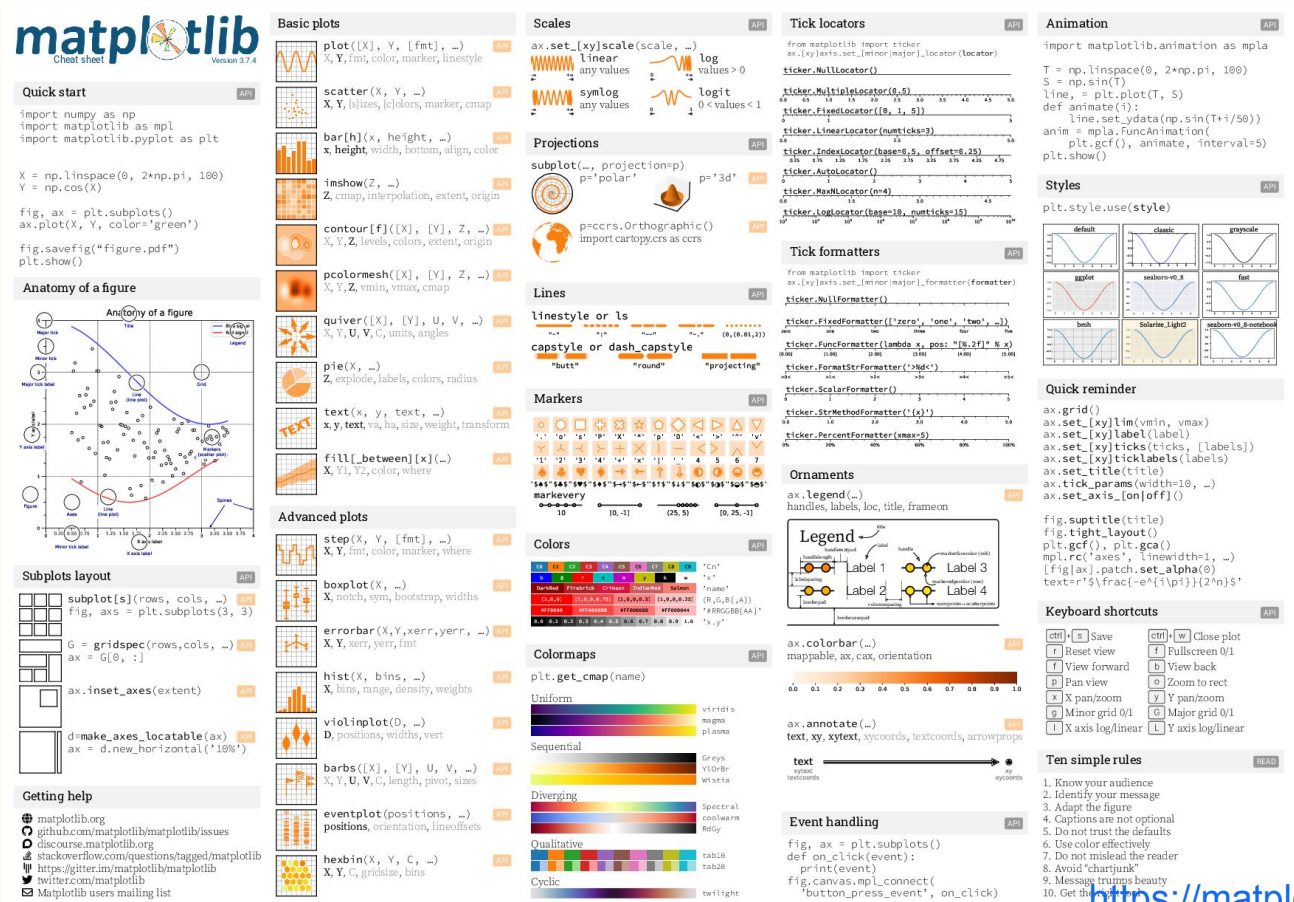

https://matplotlib.org/cheatsheets/

Visualización en Python con matplotlib

- Los 6 tipos de plots más frecuentemente usados:

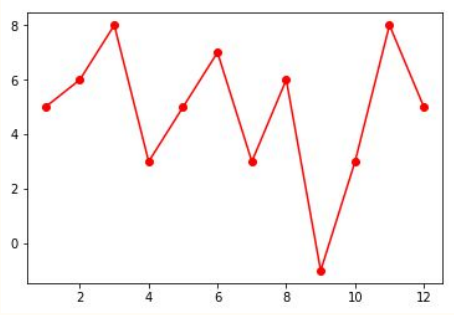

Plot de línea

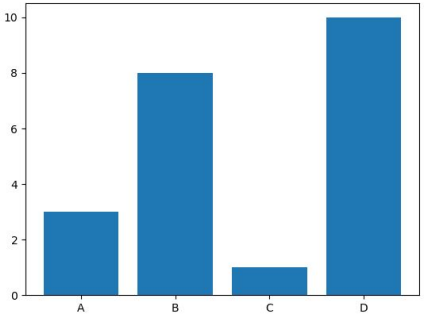

Plot de barras

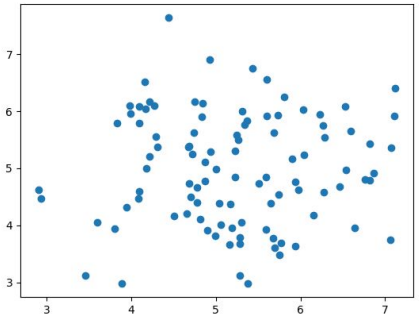

Plot de dispersión (scatter plot)

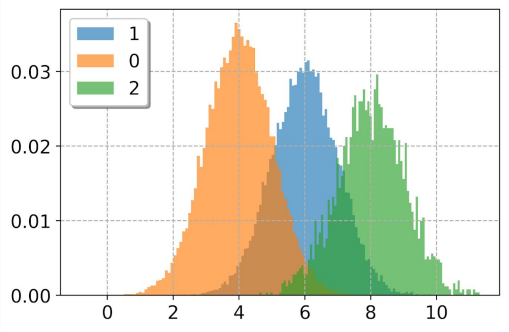

Histograma

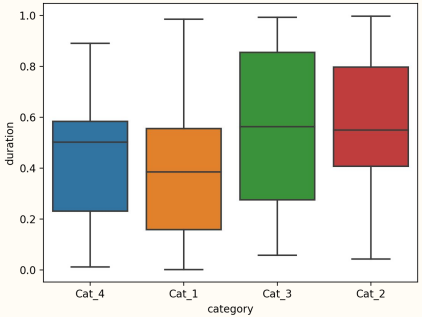

Plot de cajas (boxplot)

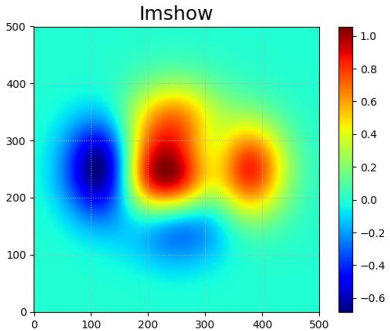

Mapa de calor

Visualización en Python con matplotlib

- **`plt.plot()`**: gráficas de líneas (i.e. datos ordenados) con marcadores opcionales

matplotlib.ipynb

```
plt.plot(tiempo, CO2, label=”CO2”)
plt.xlabel("Año")
plt.ylabel("CO2 (ppm)")
plt.title("Evolución del CO2 atmosférico")
plt.grid(ls=":")
plt.legend()
#plt.ylim(0, 450)
plt.show()
```

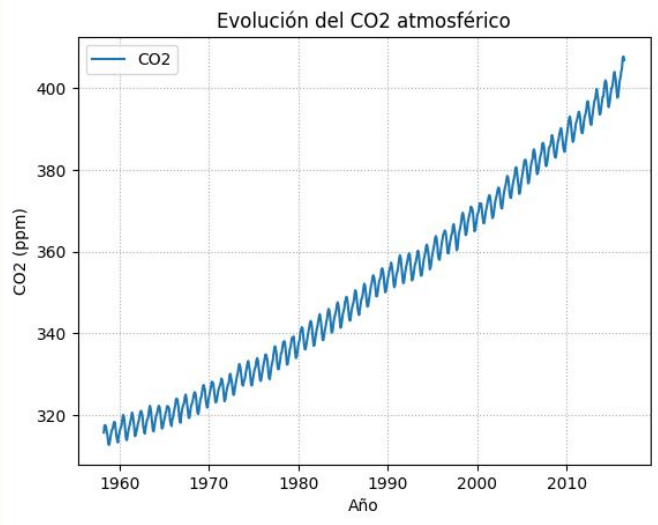

https://gml.noaa.gov/ccgg/data/

Visualización en Python con matplotlib

- **`plt.scatter()`**: scatter plots (parejas de datos no-ordenados)

matplotlib.ipynb

```
df = pd.read_csv("temp_precip.csv")
plt.scatter(df["Temp"], df["Precip"])
plt.xlabel("Temperatura (°C)")
plt.ylabel("Precipitación (mm)")
plt.title("Precipitación vs
temperatura para países del mundo")
plt.grid(ls=":")
plt.tight_layout()
plt.show()
```

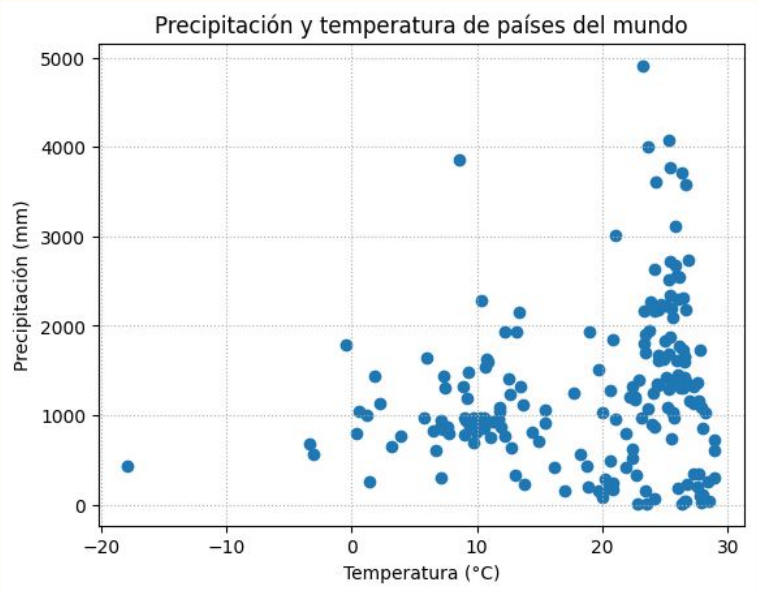

Datos de https://ourworldindata.org/

Visualización en Python con matplotlib

- **`plt.bar()`**: plots de barras

matplotlib.ipynb

```
df = pd.read_csv("temp_precip.csv")
top10_mas_lluviosos =
df.sort_values(by="Precip",
ascending=False).head(10)
plt.bar(top10_mas_lluviosos["Code"],
top10_mas_lluviosos["Precip"])
plt.xlabel("Código de país")
plt.ylabel("Precipitación anual (mm)")
plt.title("Top 10 países más lluviosos")
plt.tight_layout()
plt.show()
```

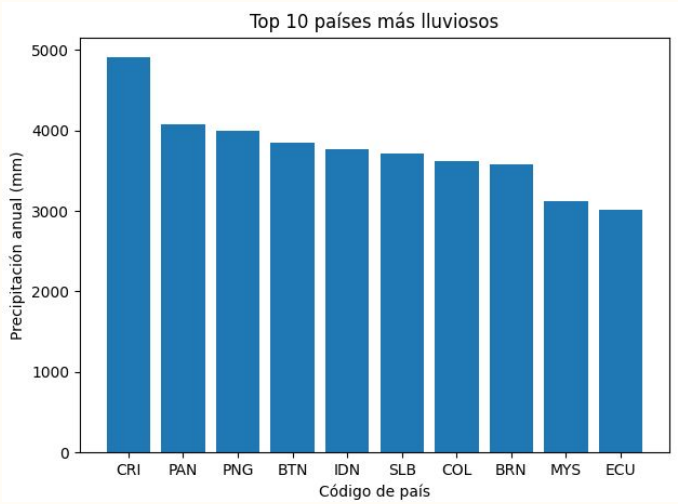

Datos de https://ourworldindata.org/

Visualización en Python con matplotlib

- **`plt.hist()`**: histogramas

matplotlib.ipynb

```
plt.hist(df["Precip"], bins=20)
#plt.hist(df["Precip"], bins=20,
histtype="step")
plt.xlabel("Precipitación anual (mm)")
plt.ylabel("Conteo de países")
plt.title("Distribución de precipitación
anual")
plt.show()
```

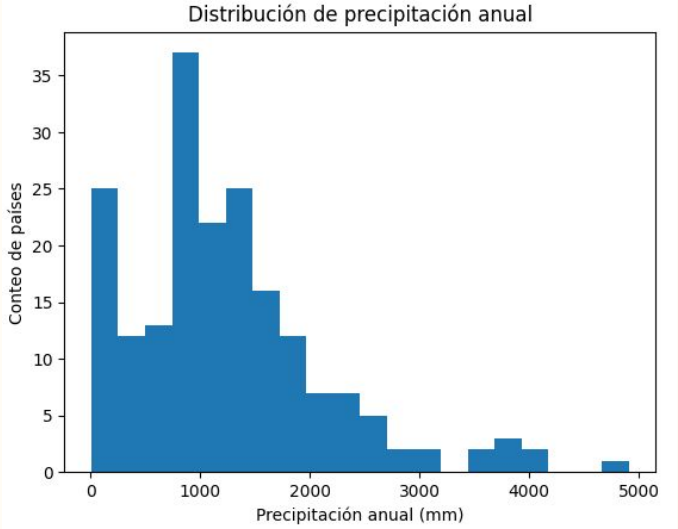

Datos de https://ourworldindata.org/

Visualización en Python con matplotlib

- **`plt.boxplot()`**: plots de cajas (boxplots)

matplotlib.ipynb

```
plt.figure()
plt.subplot(1, 2, 1)
plt.boxplot(df["Precip"])
plt.title("Precipitación")
plt.ylabel("mm")
plt.subplot(1, 2, 2)
plt.boxplot(df["Temp"])
plt.title("Temperatura")
plt.ylabel("mm")
plt.show()
```

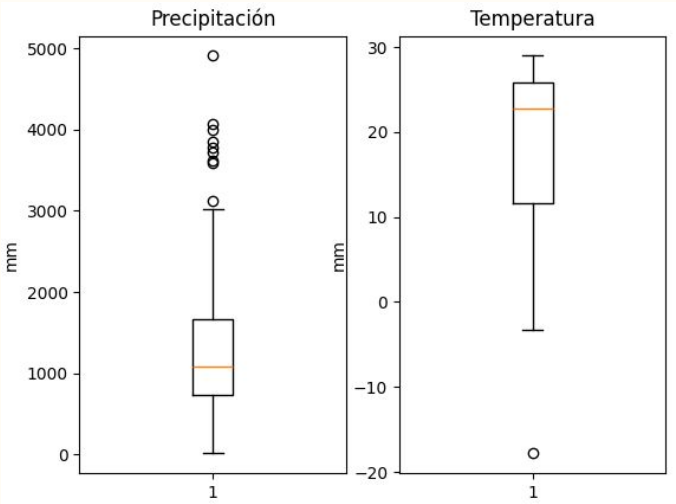

Datos de https://ourworldindata.org/

Visualización en Python con matplotlib

- **`plt.imshow()`**: mapas de color (datos 2D)

matplotlib.ipynb

➢ plot_global_temp_anomaly.py

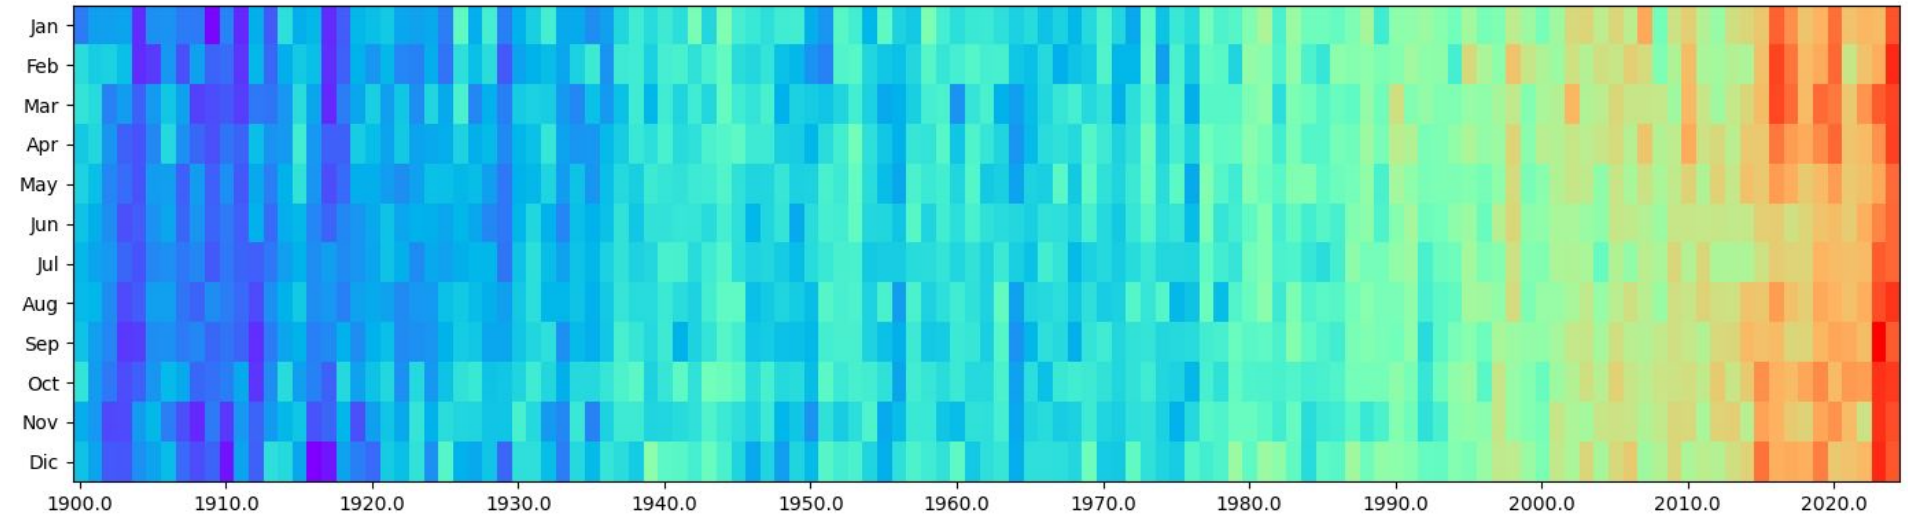

Datos de https://berkeleyearth.org

Visualización de datos geoespaciales en Python

Con la librería **`cartopy`** se pueden graficar datos geoespaciales.

https://scitools.org.uk/cartopy/

plot_temperature_map_cartopy.ipynb

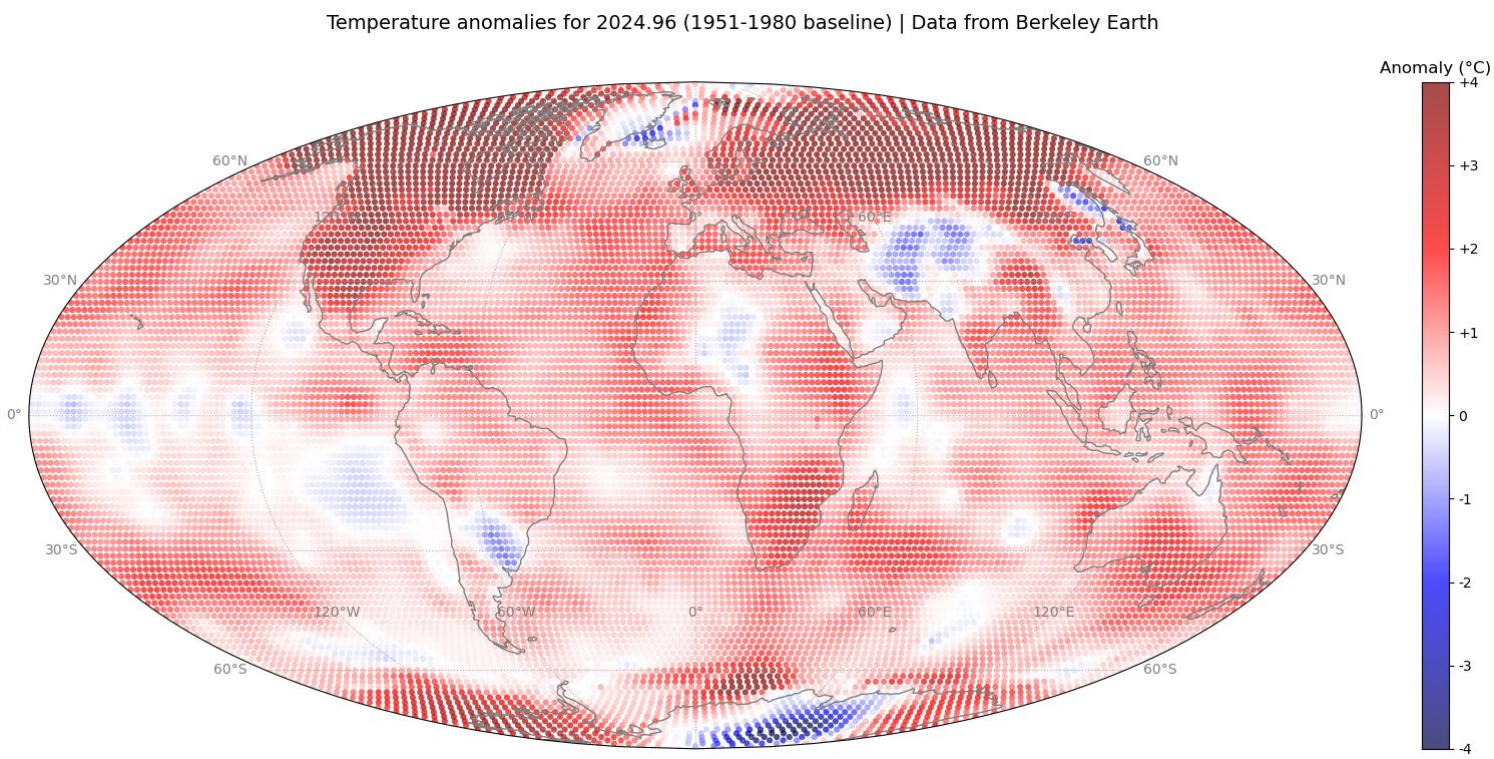

Limpieza de datos

Es el proceso de detectar y corregir datos faltantes o inválidos en un conjunto de datos.

Cuando faltan valores en un archivo, usualmente se leerán como **NaN** (Not A Number) o **NA** (Not Available)

limpieza.ipynb

Estrategias para lidiar con valores faltantes:

- **Descartar** datos inválidos
  - Filas (muestras) con NaNs en alguna columna
  - Columnas enteras (variables) si tienen demasiados NaNs
  - Elimina información
- **Imputación** de datos (rellenar)
  - Se usa la media o mediana de una columna para rellenar faltantes
  - Inventamos información que no existía; implica suposiciones sobre los datos

Ninguna estrategia es perfecta: se debe juzgar qué hacer en cada caso.

Análisis de datos: estadística descriptiva

Proporciona estadísticas numéricas simples que describen los datos:

- **Centralidad**: ¿Cúal es un valor típico?
- **Dispersión**: ¿Qué tan variables son los datos (comparado con lo típico)?
- **Rango**: ¿Qué tan ancho es el intervalo de los datos?

```
import numpy as np
import pandas as pd
x = pd.Series([10, 12, 13, 15, 100])
mean = x.mean()
median = x.median()
std = x.std()
min_val = x.min()
max_val = x.max()
q1 = x.quantile(0.25)
q3 = x.quantile(0.75)
```

Media	30.0
Mediana	13.0
Desv. Est.	39.0
Mínimo	10
Cuartil 1	12
Cuartil 3	15
Máximo	100

Análisis de datos: tendencia

Quizás la manera más sencilla de modelar la tendencia, puesto que cambia lentamente, es usando un **ajuste de curva** lineal o cuadrático.

La función **`curve_fit()`**, de `scipy.optimize`, permite hacer **ajustar un modelo** matemático (no necesariamente una línea) a datos.

Parte 1 de Concentración_de_CO2_en_Mauna_Loa.ipynb

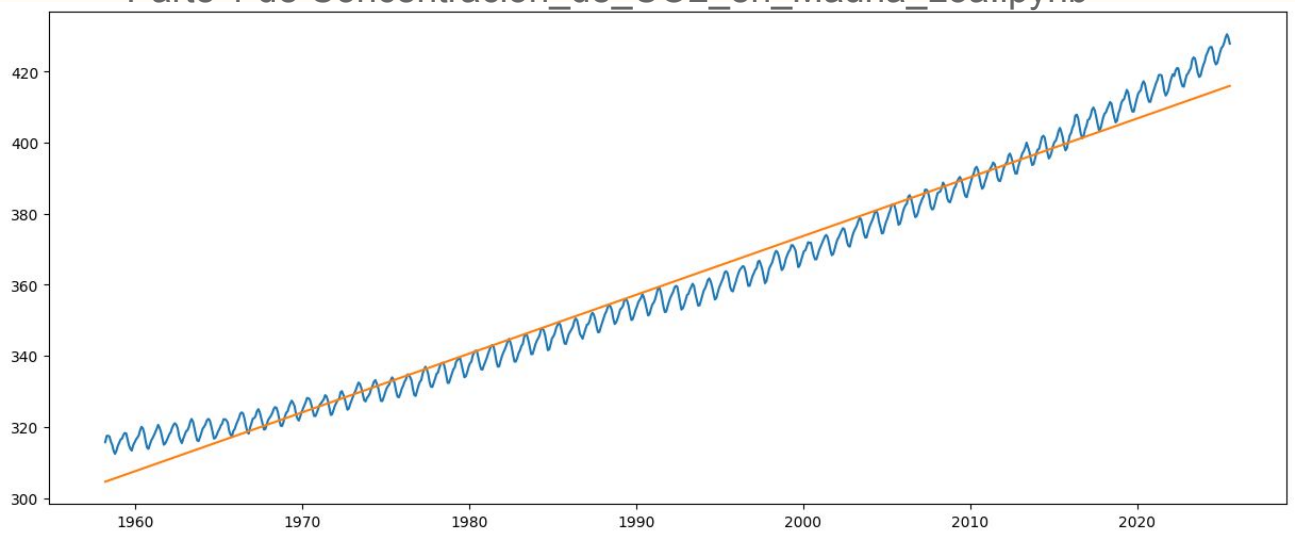

Análisis de datos: media móvil

Los modelos matemáticos simples no siempre se ajustan tan bien a los datos reales.

Otra técnica para extraer tendencia, muy simple y bastante efectiva, es el **suavizado**.

Esto elimina la variabilidad de alta frecuencia y permite separar la tendencia de las componentes periódicas.

Una manera sencilla de suavizar es calculando una **media móvil**:

$$M_t = \frac{X_t + X_{t-1} + X_{t-2} + \cdots + X_{t-N+1}}{N}$$

Media móvil al tiempo t

Promedio del valor a tiempo t
y los N-1 valores anteriores

Análisis de datos: media móvil

Pandas tiene una función integrada para calcular medias móviles (llamada en inglés moving average o también *rolling* average):

```
ts.rolling(window=N).mean()
```

Parte 2 de Concentración_de_CO2_en_Mauna_Loa.ipynb

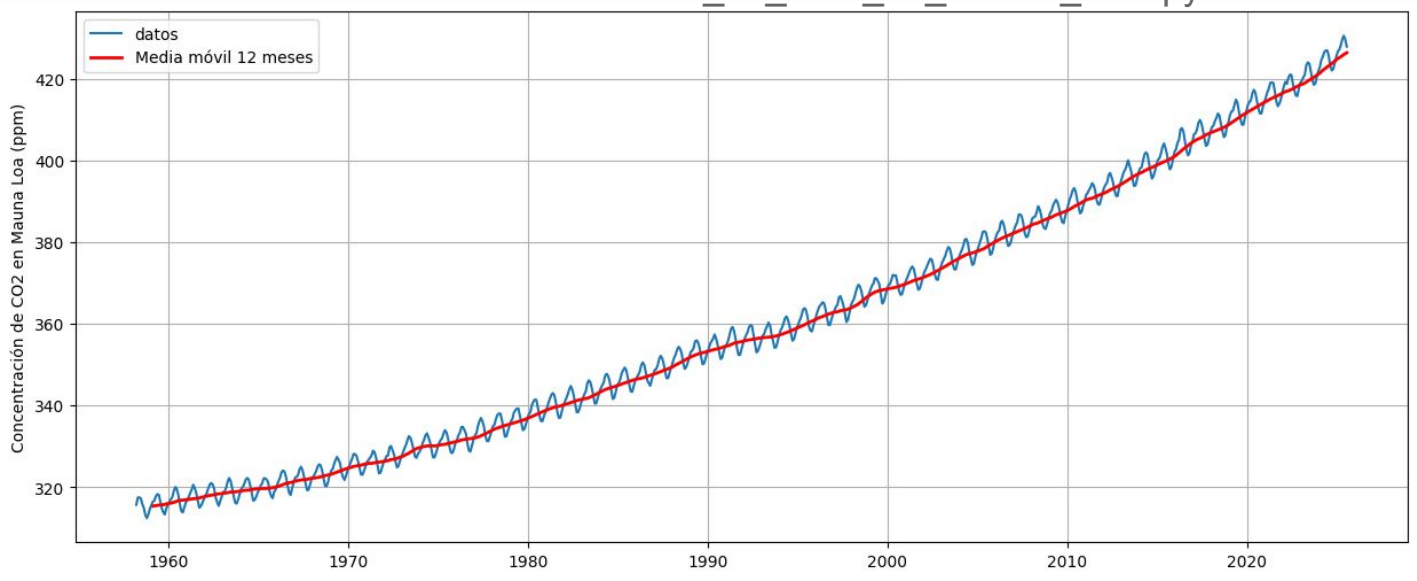

Análisis de datos: media móvil

Podemos ahora ajustar un modelo cosenoidal a la estacionalidad.

Finalmente, construimos un modelo compuesto por la tendencia (media móvil).

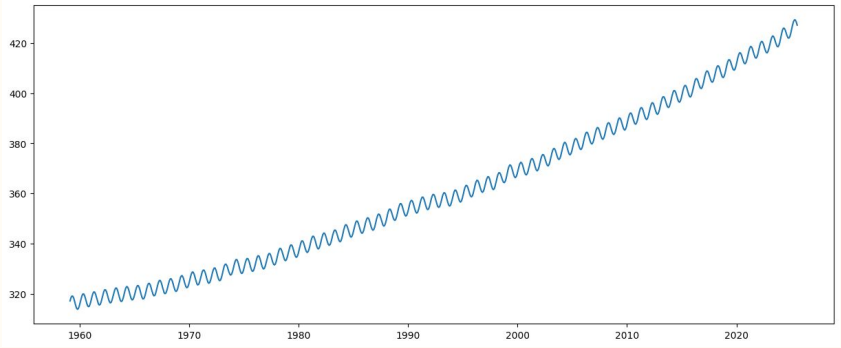

=

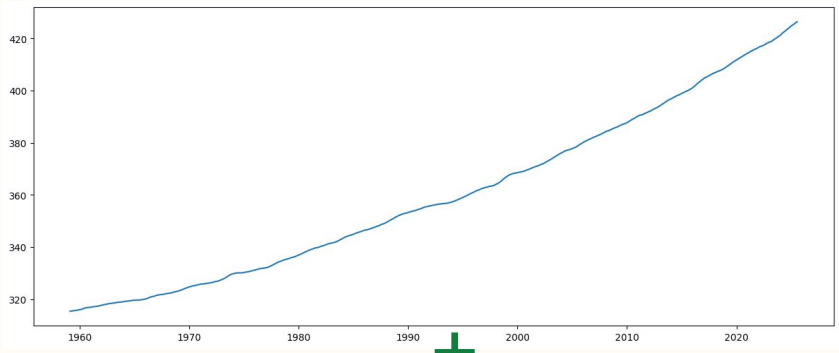

+

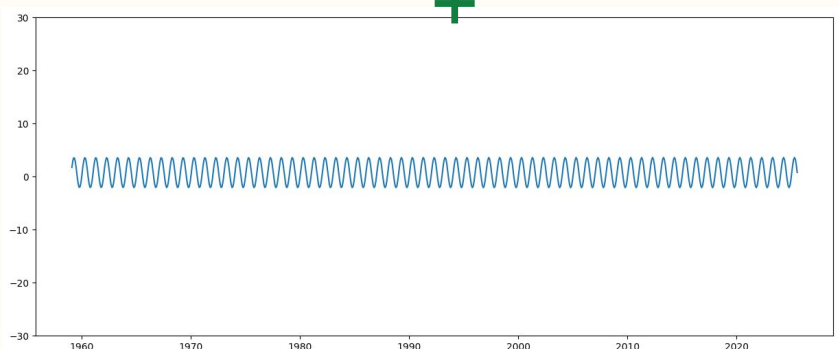

Parte 3 de Concentración_de_CO2_en_Mauna_Loa.ipynb

Análisis de datos: periodicidades

Manchas solares: regiones ligeramente más frías y por tanto menos brillantes de la superficie solar

Son un buen indicador de la actividad solar, relacionada con llamaradas y eyecciones de masa que pueden causar problemas en la Tierra y en el espacio cercano.

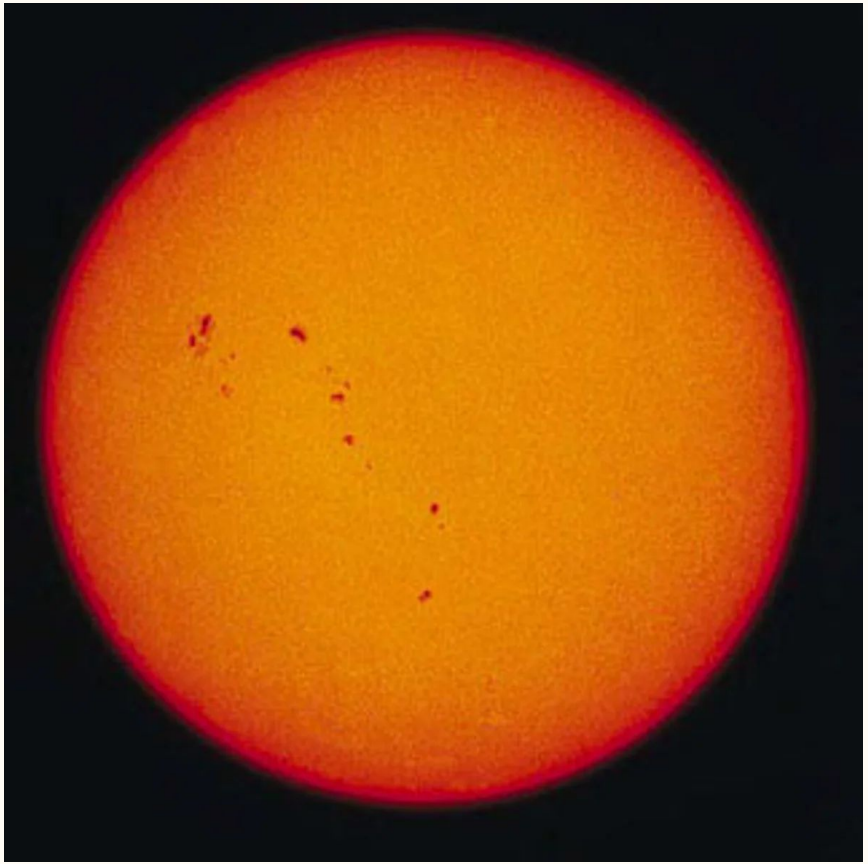

Análisis de datos: periodicidades

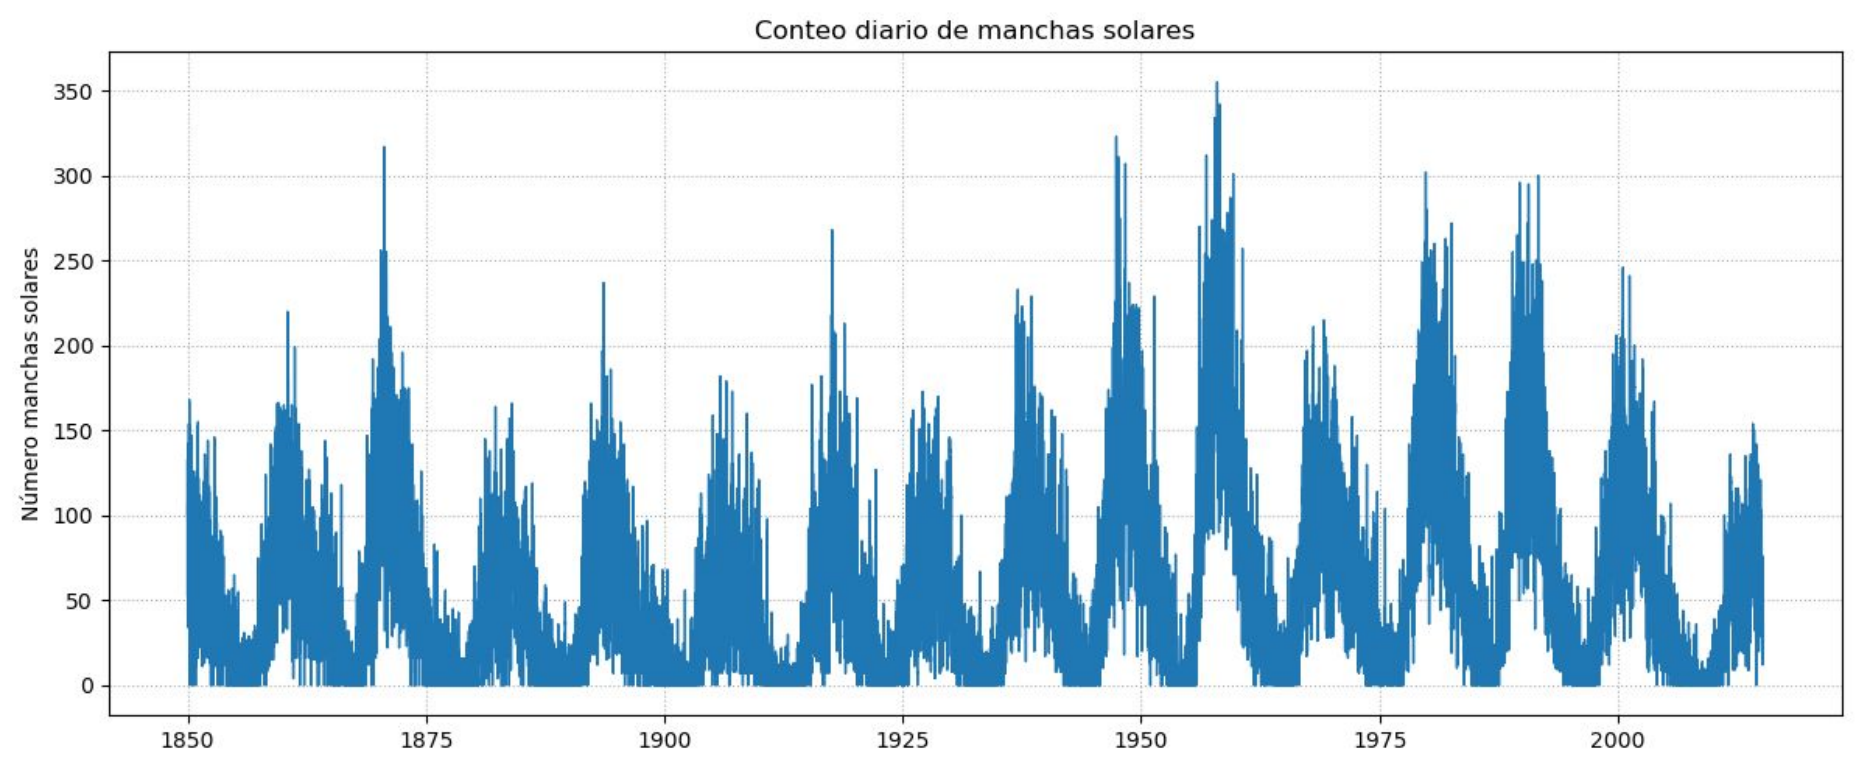

Análisis de datos: periodicidades

La **transformada de Fourier** nos permite encontrar periodicidades.

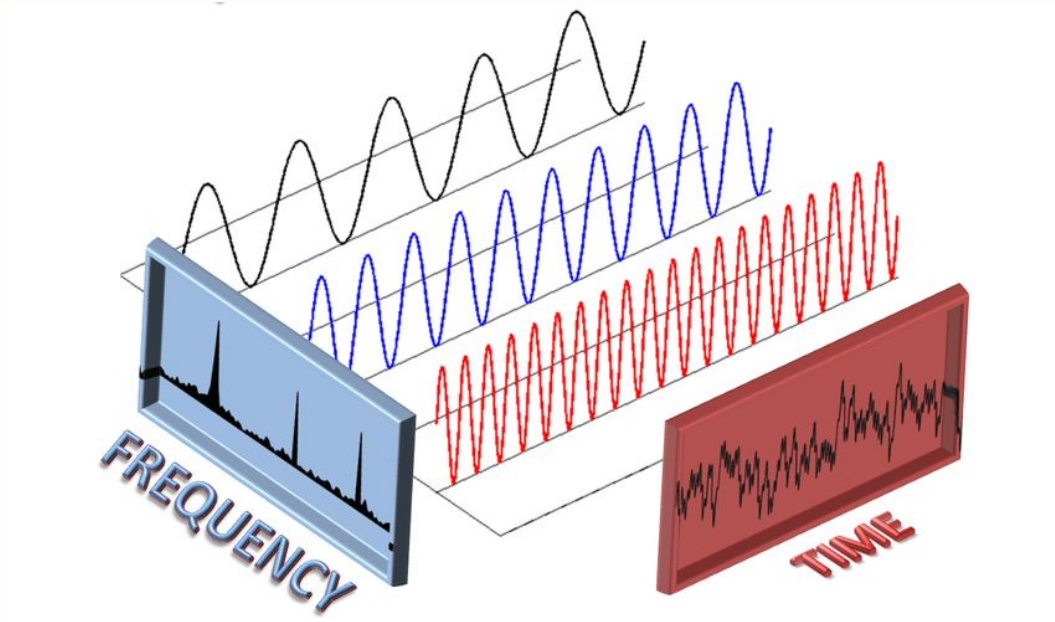

$$y[k] = \sum_{n=0}^{N-1} e^{-2\pi j \frac{kn}{N}} x[n]$$

SciPy

SciPy User Guide › Fourier Transforms (scipy.fft)

Fourier Transforms (scipy.fft)

Contents

Análisis de datos: periodicidades

La **transformada de Fourier** nos permite encontrar periodicidades.

manchas_solares.ipynb

Periodo de manchas solares: 11 años (el "ciclo solar")

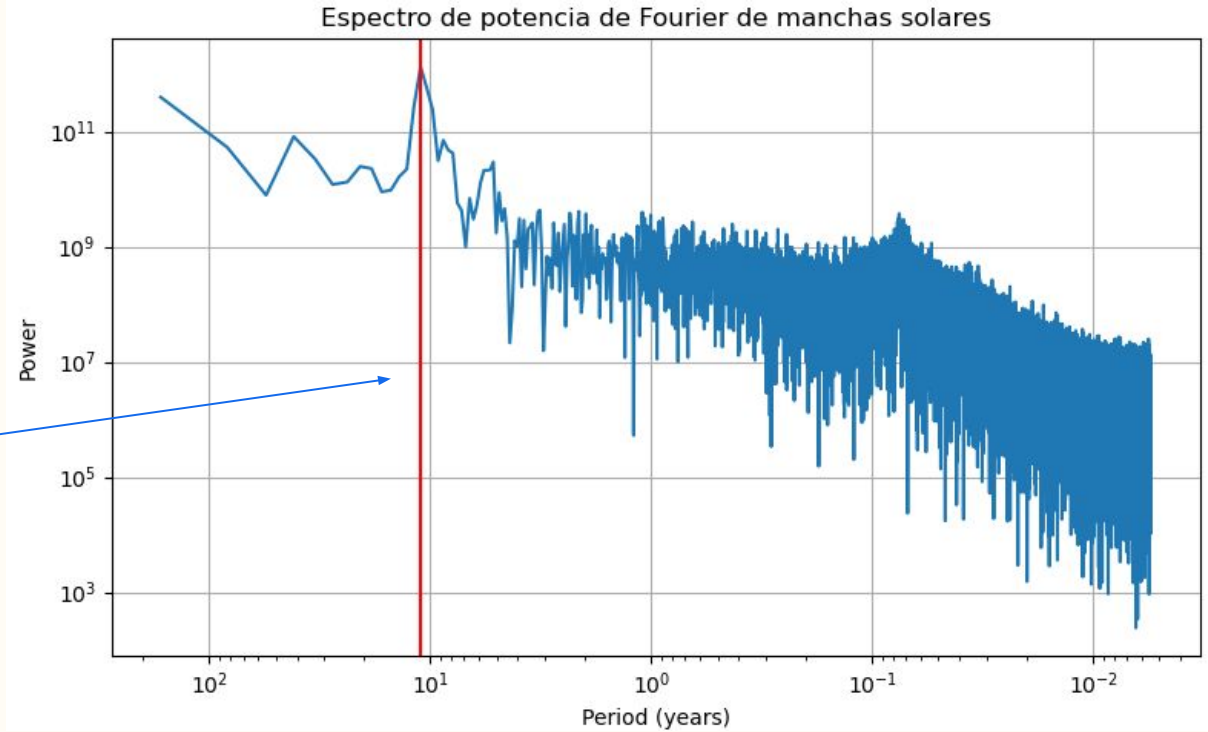

Visualización interactiva: Plotly

Plotly es una librería de Python enfocada en plots bonitos e interactivos.

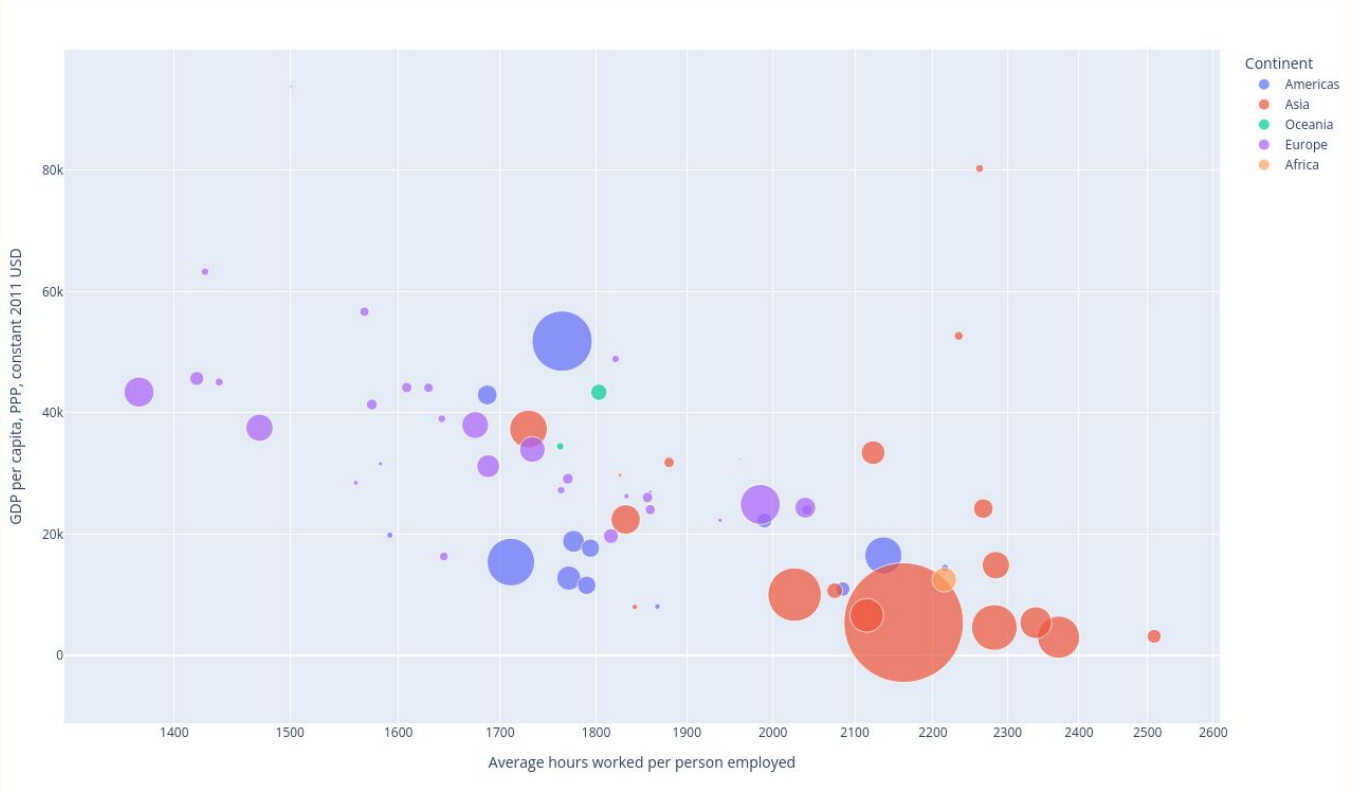

plotly_ejemplo.py

Visualización interactiva: Plotly

Una ventaja de plotly es que existe una versión de **Javascript** (Plotly.js) que puede usarse para gráficas interactivas en web.

➢ https://meithan.net/hours_worked/